Freedom CQA Studio

Материалы для технической проверки

Бибол Жайлыбаев
Команда Fantastic Four
Data Challenge 2026

Freedom CQA Studio помогает проверяющему оценивать качество клиентской поддержки по изменяемым правилам, видеть основания и сохранять решение при пересмотре. Рабочий прототип обрабатывает тексты RU KZ EN и дополнительно анализирует записи звонков.

Подтверждённый объём

Показатель	Результат
Полные оценки DEV	65 из 65 диалогов
Ответы по восьми критериям DEV	520
Контроль FBroker	10 из 10 чатов, 80 оценок
Звонки с парным распознаванием	5
Программные тесты	141 Python и 18 JavaScript

Что получает проверяющий

Карточку диалога с баллами и репликами-доказательствами. Версионируемый чек-лист с весами, шкалами и N/A. Апелляцию, решение с причиной и сохранённую исходную оценку. Дополнительно доступны резюме, рекомендации, очередь и аналитика.

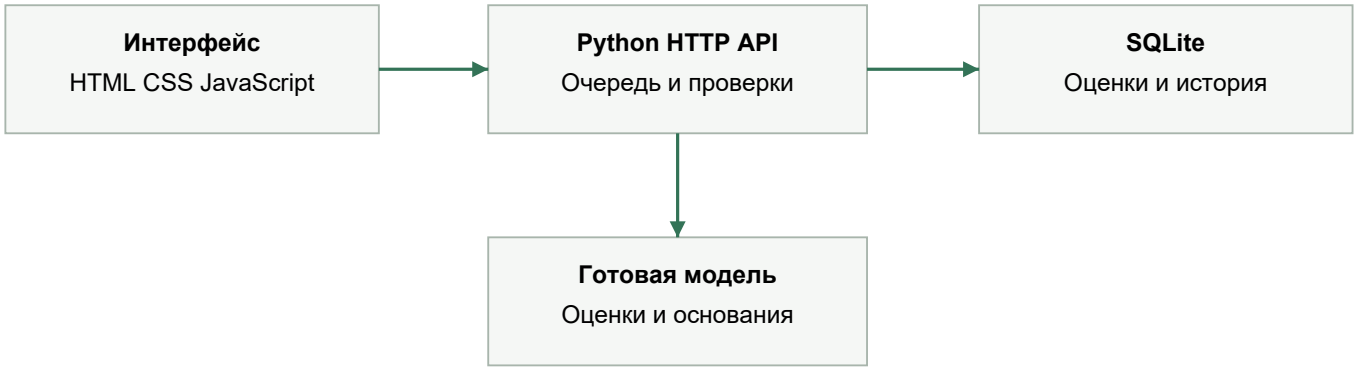
Границы результата

65/65 означает покрытие набора, а не точность модели. Независимый человеческий эталон ещё не собран. Контроль FBroker завершён: в PROD 10 записей ok. Swap сохранён без оценки. Исходные разговоры и ключи не входят в публичную поставку.

Навигация: jury/README.md — вход в пакет; jury/RUNBOOK.md — запуск; jury/REQUIREMENTS.md — соответствие заданию.

Архитектура и данные

Простой локальный сервис связывает готовую модель с проверяемым процессом оценки. Базовое приложение требует Python 3.11 или новее, интерфейс работает без внешних CDN.



Как формируется оценка

1. Сервер импортирует диалог с исходными ID, ролями и метками времени.
2. Очередь сохраняет снимок чек-листа и параметров модели.
3. Модель возвращает оценки, основания и дополнительные блоки.
4. Код проверяет допустимые значения и ссылки на источник, рассчитывает балл и сохраняет результат.
5. Проверяющий может оспорить критерий и сохранить новое решение.

Расчёт выполняет код

Итог равен взвешенной сумме нормализованных оценок, делённой на сумму применимых весов и умноженной на 100. N/A исключается из знаменателя. Числовая ступень делится на максимум шкалы. Грубая ошибка хранится отдельно и не обнуляет итог автоматически. Округление — до двух знаков.

Исходные данные и экспериментальные версии

Оригинал, читаемая редакция и независимое распознавание сохранены раздельно. Аудиособытия и ASR не пересчитывают официальный балл. В source-turns-v4 модель выбирает номера реплик, а сервер подставляет исходный текст. Наличие цитаты не доказывает правильности смыслового вывода.

Готовая модель не обучалась на DEV. SQLite и один обработчик подходят для локального MVP; роли, промышленное хранение и интеграции требуют дальнейшей разработки.

Проверка требований

Сопоставление с Student Guide v3 и Results Appendix. Полная матрица с файлами и действиями — jury/REQUIREMENTS.md.

Требование	Реализация
Настраиваемый чек-лист	Формулировки, веса, шкалы, N/A, новые критерии и версии через UI
Оценка RU KZ EN	Основной анализ транскрипта; бот и события служат контекстом
Объяснения и доказательства	Ссылки на исходные реплики, проверка значений и текста цитат
Карточка и звонки	Просмотр диалога, плеер, переход к участку записи
Апелляция и пересмотр	Комментарий, причина решения, исходная и финальная оценки
Замена критерия	Новая версия конфигурации применяется новыми заданиями
DEV Results JSON 1.0	65 записей ok; ID, типы, границы и арифметика проверены
Контроль и Git	FBroker: 10/10, PROD проверен. Код и оба файла опубликованы в GitHub

Проверка поставки

Команда **python jury/check_package.py** сверяет SHA-256 файлов, схему DEV, ID, границы номеров реплик и арифметику. Для переносимой проверки опубликованы только ID, канал, язык и количество реплик. Проверка смысла и подлинности источника требует оригинальных данных.

Условия сдачи

По правилам нужны открытый репозиторий, README и результаты DEV и PROD до стоп-кода. Локальная папка, архив или commit без push не завершают сдачу. В Git опубликованы DEV 65/65 и PROD FBroker 10/10. Swap из трёх чатов сохранён без оценки; он не включён в PROD.

Эксперименты и качество

Проверка	Наблюдение	Ограничение
Полный DEV	65/65; RU 35, KZ 15, EN 15	Покрытие, не точность
Ранний пилот	45/48 совпадений на 6 диалогах	Предварительная разметка ассистента, не человеческий эталон
low против medium	3 ID; среднее 4,60 и 5,76 с	По одному проходу, без рандомизации
ASR до и после DSP	5 звонков; 86 пар Whisper; 10 успешных запросов Gemini	WER/CER требуют ручного эталона

Различаем наблюдения и выводы

В полном DEV сохранены 51 блок резюме и рекомендаций и 54 разбора вопросов. Дополнительный блок может не пройти проверку при сохранённом основном балле. В журнале видны неудачные попытки и повторы; они не исключаются из истории.

Русский и казахский в одной записи

Gemini получает исходный и очищенный сигнал отдельными запросами без готового транскрипта. Локальная базовая модель — Whisper tiny INT8. После очистки встречаются ошибки казахских слов; автоматически считать очищенный вариант лучшим нельзя. На сайте есть ручной эталон, WER/CER и экспорт сравнения.

Звук не доказывает намерение

Паузы, кашель, одновременная речь и интонационные признаки показываются как наблюдения для прослушивания. Тихий участок не доказывает игнорирование, кашель не является диагнозом, воспринимаемая манера речи не равна внутреннему эмоциональному состоянию.

Денежная стоимость не определена: тарифы не заданы, часть usage неизвестна. Экономия времени, удержание и связь с CRM не измерены. Источники чисел: jury/evidence и документы VALIDATION, FULL_DEV_RUN, ANALYTICS_VALIDATION, ASR_VALIDATION.

Защита и техническое интервью

Время	Действие
0:00–0:40	Проблема, пользователь и один выбранный диалог
0:40–2:10	Оценка, вес, N/A, доказательство и переход к реплике
2:10–3:10	Апелляция, причина решения и пересчитанный результат
3:10–4:10	Изменение критерия, новая версия и запуск задания
4:10–5:00	Файл DEV, тесты, один аудиоэкран и ограничения

Что стоит объяснить самостоятельно

Где наша работа? Правила, проверка ответа, расчёт, очередь, хранение и пересмотр. Используется готовая модель, разработка велась с AI-ассистентом. Личный вклад участник описывает только по действительно выполненным действиям.

Какая точность? 65 обработанных диалогов не дают 100% точности. Ранние 45/48 относятся к малой выборке и разметке ассистента. Нужен независимый человеческий эталон и новые данные.

Что при ошибке? Прежний результат сохраняется, состояние задания видно в очереди. Неопределённый запрос после перезапуска не повторяется молча; доступен явный повтор.

Следующие инженерные шаги

Собрать независимую разметку RU KZ EN и смешанной речи, измерить ошибки по критериям и пропуски грубых нарушений. Затем добавить проверенную базу знаний, управление доступом и правила хранения. Для бизнес-эффекта нужны измерения времени проверяющего или подтверждённые исходы CRM.

Быстрый запуск из архива: START_DEMO.cmd → http://127.0.0.1:8766. Три чата синтетические, выводы получены правилами, не AI. Для реального анализа нужны официальный JSON и ключ выбранного провайдера.

Источники требований: CQA Hackathon Student Guide v3, стр. 1–4; CQA Student Guide Appendix Results, стр. 1–3. Подробная инструкция и ответы: jury/DEMO_AND_QA.md.